

# Análisis y Predicción de Deserción de Clientes (Churn) en Telecomunicaciones

Proyecto de Fin de Semestre - Asignatura: Aplicaciones  
de la matemática en ingeniería

---

Antonio Aguilar, Nicolás Lara, Diego Sandoval,  
Rodrigo Montecinos, Christopher Martínez

30 de noviembre de 2025

Universidad Técnica Federico Santa María  
Departamento de Matemática

# Definición del Problema

## Deserción de Clientes (Churn)

La alta rotación de clientes genera un problema estratégico para las empresas de telecomunicaciones:

- **Costo Alto:** Retener es entre  $\times 5$  y  $\times 7$  más barato que adquirir un nuevo cliente.
- **Impacto Directo:** El churn reduce la rentabilidad y el valor de vida del cliente.
- **Necesidad Clave:** Anticipar el abandono permite focalizar acciones de retención.



# Definición Técnica del Problema

## Naturaleza del Problema


El churn es una **variable binaria**:

Churn = 1 (abandona)

Churn = 0 (permanece)

El dataset *Telco Customer Churn* incluye:

- **7.043 clientes y 21 variables.**
- **Variables mixtas:** numéricas y categóricas.
- **Desbalanceo de clases:** mayoría de clientes permanecen.



# Objetivo General del Proyecto

## Propósito Central

Desarrollar un modelo predictivo capaz de identificar clientes con alta probabilidad de abandono (*churn*), utilizando el dataset *Telco Customer Churn*, para apoyar decisiones estratégicas de retención y mejorar la rentabilidad del negocio.


# Objetivos Específicos

## Metas del Proyecto

- **Analizar y preprocessar el dataset (EDA, limpieza, codificación).**
- **Entrenar y comparar modelos de clasificación binaria.**
- **Interpretar resultados para identificar factores que influyen en el churn.**




# El Desafío: Desbalance de Clases




El 26.5 % de los clientes abandona la compañía.

# El Factor Tiempo: ¿Cuándo se van?




El riesgo es crítico en los primeros meses.

# El Compromiso: Tipo de Contrato




Contratos mensuales = Alto Riesgo (40 % Churn).

# El Factor Económico: Sensibilidad al Precio



A mayor cargo mensual, mayor probabilidad de fuga.

# Estadística y Preprocesado: Correlaciones



- Alta colinealidad detectada (Tenure vs TotalCharges).
- **Estrategia de Preprocesado:** Selección de features + SMOTE (Balanceo).

# Metodología de Evaluación Rigurosa

## Objetivo

Garantizar la robustez de las predicciones y evitar el sobreajuste (overfitting).

## Métricas Clave:

- ROC-AUC: Métrica principal para balancear sensibilidad y especificidad.
- Matriz de Confusión, F1-Score, Accuracy.

## Validación Cruzada:

- *Stratified K-Fold* ( $k = 5$ ).
- Entrenamiento con datos balanceados (**SMOTE**).

# Optimización: Modelos Base

Se implementaron modelos clásicos utilizando búsqueda exhaustiva de hiperparámetros (**Grid Search**).

Modelo	Configuración Clave
Regresión Logística	Penalización L2, Solvers optimizados.
SVM	Kernel RBF, ajuste de Gamma y C.
KNN	Distancia Minkowski, ponderación por distancia.

## Nota Técnica

Se priorizó la probabilidad ('predict\_proba') para el cálculo preciso de la curva ROC.

# Optimización: Modelos de Ensamble

Para capturar patrones complejos no lineales, escalamos a modelos basados en árboles.

## Random Forest

- **Estrategia:** Grid Search.
- **Foco:** Profundidad máxima y número de estimadores.
- Reducción de varianza mediante *bagging*.

## XGBoost

- **Estrategia:** Randomized Search.
- **Foco:** Learning rate y submuestreo.
- Eficiencia computacional mediante *boosting*.

## Resultados: Resumen Cuantitativo

Evaluación sobre el conjunto de prueba (Test Set) tras la optimización.


Modelo	Accuracy	Recall	F1-Score	ROC-AUC
Logistic Regression	0.778	<b>0.636</b>	<b>0.603</b>	<b>0.824</b>
XGBoost	<b>0.782</b>	0.607	0.597	0.818
Random Forest	0.769	0.588	0.575	0.807
SVM	0.776	0.588	0.583	0.805
KNN	0.743	0.626	0.565	0.786

### Hallazgo Clave


Aunque **XGBoost** tiene la mayor exactitud global, la **Regresión Logística** domina en capacidad de detección (Recall y AUC).

# Análisis Visual: El "Trade-off"

Comparación de curvas ROC y Matrices de Confusión.  
**Logistic Regression**



*Detecta mejor los positivos  
(Churners).*



*Menos falsos positivos, pero  
pierde churners.*

# Selección del Modelo y Justificación

## Criterio de Negocio: Minimizar Falsos Negativos

En un contexto de *Churn* o Fraude, es más costoso perder un cliente (o no detectar un fraude) que revisar una falsa alarma.

### ¿Por qué gana Logistic Regression?

- Mejor Recall (63.6 %): Atrapamos más casos reales.
- Mejor ROC-AUC (0.824): Mejor separación global de clases.
- Interpretabilidad: Permite entender qué variables influyen en la decisión.



Modelo Robusto

# Resultados: Interpretación de Coeficientes


## Factores de Alto Riesgo (+):

- **Pago Electrónico:** El predictor más fuerte de abandono.
- **Contrato Mes a Mes:** La inestabilidad contractual aumenta el riesgo.
- Falta de Seguridad/Backup Online.


## Factores de Retención (-):

- **Servicio DSL:** Menor riesgo vs Fibra Óptica.

\*Nota Técnica: La negatividad en PhoneService sugiere colinealidad con MultipleLines (redundancia de información).



# Validación y Refinamiento: Valores SHAP



## Resolviendo la Colinealidad:

- SHAP distribuye el impacto real entre variables correlacionadas.
- **Resultado:** *PhoneService* desaparece del top de importancia, confirmando que era redundante.

## Nuevo Hallazgo (MonthlyCharges):

- Los puntos rojos (Cargos Altos) están a la izquierda.
- *Interpretación:* Clientes que pagan más tienen menor riesgo de fuga (efecto "amarre" por tener más servicios contratados).

# Conclusiones del Proyecto

- Problema: predicción de **churn** en una empresa de telecomunicaciones (dataset Telco Customer Churn).
- Tarea de **clasificación binaria** supervisada: estimar la probabilidad de abandono para cada cliente.
- Objetivo doble: **buen desempeño predictivo + interpretabilidad**.

## Hallazgos Clave de Datos y Modelado

- Dataset **desbalanceado** ⇒ uso de **SMOTE** en entrenamiento.
- Patrones por categoría:
  - Contratos **Month-to-month** y pagos **Electronic check** ⇒ churn alto.
  - Pagos **automáticos** y contratos de **1-2 años** ⇒ menor churn.
  - **Falta** de servicios aumenta el riesgo.
- Comparación de modelos: **Logistic Regression** obtiene las mejores métricas y se elige como **modelo campeón**.

# Factores de Riesgo y Segmentos Clave

- Análisis de coeficientes + SHAP:
  - Segmento de **alto riesgo**: clientes nuevos, con contrato mensual, sin servicios adicionales y que pagan manualmente.
  - Segmento de **bajo riesgo**: clientes antiguos, con contratos de largo plazo, servicios extra y pagos automáticos.
- El modelo captura efectos condicionados que no siempre coinciden con las correlaciones simples vistas en el EDA.

## Recomendaciones y Líneas Futuras

- Campañas **focalizadas**
- Estrategia de contratos **a largo plazo**
- Pagos **automáticos** y servicios  **adicionales**
- **Fidelización** y cross-selling
- **Trabajo futuro:** más *feature engineering*, modelos avanzados y mejor tratamiento de colinealidades.

¡Gracias por su atención!